



POS Tagging com Arquiteturas Neurais: Relatório de Resultados

Uma Análise Comparativa no Penn Treebank

Jeremias Pinheiro de Araujo Andrade, Lucas Apolonio de Amorim, Moisés Ferreira de Lima

Universidade Federal do Rio Grande do Norte (UFRN)

DIM0135 - Processamento de Linguagem Natural — 2026



O Penn Treebank como Base para Análise de POS Tagging

IMPORTÂNCIA DO CORPUS

O corpus Penn Treebank foi utilizado como base fundamental para a avaliação das arquiteturas neurais na tarefa de Part-of-Speech (POS) Tagging.

A metodologia seguiu a divisão determinística padrão estabelecida na literatura para garantir a comparabilidade dos resultados obtidos.


TREINO • SEÇÕES 00-18

38.219 sentenças




VALIDAÇÃO • SEÇÕES 19-21

5.527 sentenças



TESTE • SEÇÕES 22-24

5.462 sentenças



Soluções para Embeddings, Palavras Desconhecidas e Preenchimento

Desafios de Engenharia

A implementação exigiu o tratamento de desafios fundamentais de pré-processamento para estabilizar o treinamento das redes:

- Ajuste Fino de Embeddings
- Tratamento de OOV (UNK)
- Normalização de Tamanho (PAD)

01. Embeddings

Utilização da matriz pré-treinada **GloVe6B**. A camada não foi congelada, permitindo o fine-tuning/post-training durante o processo.

02. Unknown Words

Implementação do token especial **<UNK>** para lidar com palavras fora do vocabulário, com tamanho de vocabulário fixado entre 8.000 e 15.000 palavras mais frequentes (A depender da arquitetura implementada).

03. Padding

Inserção do token **<PAD>** no final das sequências para uniformizar o comprimento das sentenças.



Estratégia Experimental para Redes Recorrentes



Metodologia de Controle

O experimento com redes recorrentes isolou a influência da complexidade celular e da direcionalidade no processamento de sequências.

Variáveis e Parâmetros

■ **Modelos:** RNN Unidirecional, LSTM Unidirecional, RNN Bidirecional e LSTM Bidirecional.

■ **Espaço de Busca:** 47 tags únicas de POS (Part-of-Speech).

■ **Hiperparâmetros Fixos:** Embeddings de 50 dimensões, 128 unidades ocultas e otimizador Adam.

■ **Limites:** Comprimento máximo de 249 tokens por sequência e teto de 5 épocas de treinamento.




LSTM Bidirecional Lidera Desempenho

com Alto Custo Computacional

Arquitetura	Acurácia Global	Média Macro da F1	Tempo / Passo
RNN Unidirecional	90,88%	0,8269	22,75ms
LSTM Unidirecional	92,10%	0,8465	9,86ms
RNN Bidirecional	94,16%	0,8761	41.6ms
LSTM Bidirecional	94,68%	0,8902	14.17ms

Matriz de Confusão - Redes Recorrentes



Arquiteturas Transformer: Encoder, Decoder e Híbrido

Configuração Base

Vetorização com GloVe 300d

Foram desenvolvidas três variações baseadas no mecanismo de atenção, todas alimentadas pela matriz GloVe 6B (300 dimensões).

Esta abordagem garante que todos os modelos partam de um espaço semântico unificado de alta dimensionalidade, permitindo comparar de forma justa a capacidade de generalização e otimização de cada arquitetura de atenção.

Variantes Implementadas

■ **Transformer Encoder-Only** Construído com 2 blocos, 4 cabeças de atenção e 5.621.959 parâmetros treináveis.

■ **Transformer Decoder-Only** Configurado com 1 bloco com máscara causal (impedindo acesso ao contexto futuro) e 5.105.403 parâmetros.

■ **Transformer Encoder-Decoder** Utiliza Cross-Attention e a técnica de Teacher Forcing. Emprega um espaço de embedding exclusivo e reduzido (64 dimensões) para as tags, totalizando 5.210.344 parâmetros.

Encoder-Decoder Supera Variações com 94,40% de Acurácia

RESULTADOS DA VALIDAÇÃO

Os resultados no conjunto de validação demonstraram a superioridade das arquiteturas com acesso irrestrito ao contexto da sentença:

Encoder-Decoder (94,40%): A separação dos embeddings de tags (64d) simplificou a modelagem da sequência pelo decodificador.

Encoder-Only (93,93%): Alcançou boa acurácia, demonstrando forte capacidade de classificação local.

Decoder-Only (92,77%): A máscara causal penalizou severamente o modelo, provando que a classificação gramatical em inglês depende fundamentalmente de termos subsequentes.

94,40%

ENCODER-DECODER (MELHOR)

93,93%

ENCODER-ONLY

92,77%

DECODER-ONLY (CAUSAL)



Padrões de Erro Variam Conforme a Visão de Contexto

Os mapas de calor dos Transformers mostram vulnerabilidades ligadas à topologia de cada rede:

ENCODER-ONLY

Concentra erros em classes morfológicamente semelhantes, confundindo substantivos próprios no plural (NNPS) com comuns no plural (NNS).


DECODER-ONLY

Exibe alta dispersão de erros fora da diagonal principal, com severa dificuldade em discernir adjetivos (JJ) e advérbios (RB) devido à restrição do contexto futuro.


ENCODER-DECODER

Apresenta a matriz mais limpa, porém sofre com desvios entre passado simples (VBD) e particípio (VBN), um reflexo de sua natureza autorregressiva.

Padrões de Erro Variam Conforme a Visão de Contexto




Matriz de Confusão - Decoder-Only



Matriz de Confusão - Encoder-Only



Padrões de Erro Variam Conforme a Visão de Contexto



Matriz de Confusão - Encoder-Decoder

MISTRAL AI

LLM utilizada para a tarefa de POS-Tagging

■ **Pontos fortes:** Eficiência e baixa latência, janela de contexto, bom custo benefício, saída bem estruturada;

■ **Pontos fracos:** Racioncinio lógico de grande alcance, memorização de conhecimento específico, nuances culturais;

■ **Valências para POS-Tagging:** Boa compreensão sintática, resolução de ambiguidade, formatação confiável, velocidade;

■ **Dificuldades para POS-Tagging:** Tokenização de palavras compostas, inconsistência de taxonomia, alucinação em casos difíceis;

Expectativa

Esperam-se bons resultados nos três casos, mas não um desempenho excepcional

Estratégias de Prompting para LLMs Comerciais

Avaliação de In-Context Learning (ICL) em Ambiente de Produção

Pipeline de Chamada de API

A avaliação de Large Language Models foi estruturada via API, exigindo respostas escritas em formato de array JSON sem re-tokenização. Três abordagens de In-Context Learning foram testadas:

- **Zero-shot:** Prompt contendo apenas instruções de sistema e a sentença, dependendo exclusivamente do pré-treinamento.
- **Few-Shot:** Inclusão de 5 exemplos rotulados fixos no prompt, reutilizados independentemente do conteúdo da sentença de teste.
- **RAG (Retrieval-Augmented Generation):** Recuperação dinâmica das 5 sentenças mais similares do pool de treino via índice TF-IDF e similaridade de cosseno para compor o prompt.



```
{
  "tokens": [
    (...)
  ],
  "gold": [
    (...)
  ],
  "pred": [
    (...),
  ]
}
```

RAG e Few-Shot Maximizam Acurácia e Aderência de LLMs

ANÁLISE DE ESTABILIDADE

A presença de exemplos no prompt demonstrou ser crucial tanto para a precisão linguística quanto para a estabilidade da formatação JSON.


A diferença estatística de acurácia entre Few-shot estático e RAG foi discreta (+0,48%), sugerindo que os exemplos estruturados servem mais para calibrar o espaço de rótulos do que para fornecer contexto temático adicional.

ESTRATÉGIA	ACURÁCIA	FALHA FORM.
RAG (Retrieval)	94,39%	14,00%
Few-shot (Estático)	93,91%	11,00%
Zero-shot	91,75%	15,00%


ESTABILIDADE E ACURÁCIA

O método **Few-shot** oferece o melhor equilíbrio, atingindo alta acurácia (93,91%) com a menor taxa de falhas estruturais (11%) entre as abordagens.

Padrões de Erro Variam Conforme a Visão de




Matriz de Confusão - Zero Shot



Matriz de Confusão - Few Shot



Padrões de Erro Variam Conforme a Visão de Contexto



Matriz de Confusão - RAG

Ambiguidade Linguística e Alucinações de Formato em LLMs

As LLMs compartilham ambiguidades inerentes ao tagset do Penn Treebank, mas também apresentam erros exclusivos de formatação:

Fenômenos de Alucinação Sintática

■ **Erros Compartilhados:** Confusão persistente entre adjetivos/advérbios comparativos (JJR vs RBR) e passado/particípio (VBD vs VBN).

■ **Alucinações Zero-shot:** Sem exemplos, o modelo inventou tags inexistentes no PTB (como 'PUNCT') e falhou em resolver ambiguidades finas (WP vs WDT).

■ **Vazamento RAG:** Em casos isolados, o modelo retornou a própria palavra de entrada em vez da tag gramatical.

Conclusão


Demonstrações no prompt comunicam o formato esperado e o espaço de rótulos válidos.

Comparativo Global: Transformers vs. LLMs vs. RNNs

CONFRONTO DIRETO

O confronto direto entre as três famílias de arquiteturas destaca a superioridade dos modelos baseados em atenção:

- **Liderança:** A LSTM bidirecional treinado com embeddings de 50 dimensões do GloVe obteve a maior acurácia absoluta do projeto (94,68%).
- **Competitividade da LLM:** A LLM Comercial com RAG empatou estatisticamente (94,39%), mas requer validação externa devido a falhas de formatação (14%).
- **Modelos Causais:** Redes com restrição de contexto futuro (RNN Uni e Decoder-Only) apresentaram os piores desempenhos em suas respectivas categorias.



Próximos Passos

- Testar com embeddings que não foram pré-treinados e com embeddings pré-treinados sem post-training.
- Testar os Transformers com subword tokenization e comparar a performance com embeddings de palavras inteiras.
- Testar um Encoder-Only e Encoder Block do Encoder-Decoder Pré-Treinado (usar o BERT)
- Gerar Matrizes de Confusão sem tags de pontuação e Sub-Matrizes dos clusters com alta taxa de confusão.
- Utilizar a LLM Comercial para realizar o Parsing da Árvore Sintática das sentenças (e avaliar usando as métricas do PARSEVAL, implementadas no evalb).
- Testar Parsing Generativo com Encoder-Decoder e Decoder-Only
- Testar outras estratégias para a escolha de vocabulário (Ex: Top p% palavras mais frequentes, palavras com pelo menos k ocorrências).
- Testar os Trade-Offs entre usar embeddings de baixa dimensionalidade e a performance do modelo na LSTM.

Conclusões

Contexto Futuro e Regularização Estrutural

A Necessidade da Bidirecionalidade

A classificação morfológica em inglês é **estritamente dependente** da leitura de palavras subsequentes. Modelos com restrição causal sempre subperformaram.

Efeito de Regularização

Isolar a geração de tags no Decoder de um Transformer, utilizando **embeddings reduzidos (64d)**, provou ser uma técnica de regularização altamente eficaz.

O Papel das LLMs

O aprendizado em contexto (RAG/Few-shot) torna as LLMs **comerciais competitivas** em acurácia (94,39%), mas a dependência de parsers rigorosos para garantir a integridade do JSON traz um gargalo operacional.

NLP